

1 Цель работы

Целью данной работы является изучение основных этапов построения простейшей поисковой системы. В рамках работы требуется сформировать корпус документов, подготовить его для последующей обработки, проанализировать статистические свойства текстов, а также реализовать индексирование и поиск по документам. Дополнительно необходимо рассмотреть примеры работы существующих поисковых систем и выявить их основные недостатки.

2 Описание данных

В качестве источника данных был выбран корпус статей из англоязычной версии Википедии, относящихся к тематике видеоигр. Данный источник предоставляет открытый программный интерфейс (API), позволяющий автоматически получать тексты статей и метаданные. Для формирования корпуса была выбрана корневая категория *Video games*, обход которой осуществлялся рекурсивно с ограничением глубины.

В результате работы парсера был сформирован корпус из **30 000 документов**. Каждый документ сохранён в отдельном текстовом файле и содержит основной текст статьи без служебной разметки. Для каждого документа также формируется файл метаданных, содержащий идентификатор документа, заголовок статьи, ссылку на источник и размер файла.

Средний размер текстов в корпусе составляет **7057**, медианный размер — **3989**. Минимальный и максимальный размеры документов составляют **201** и **308614** символов соответственно.




Рис. 1: количество символов в документах




Рис. 2: пример текста

3 Закон Ципфа

Для анализа статистических свойств корпуса был рассмотрен закон Ципфа, описывающий распределение частот слов в естественных языках. Для этого на основе результатов токенизации и стемминга были подсчитаны частоты всех уникальных словоформ корпуса. Слова были отсортированы по убыванию частоты, после чего для каждого слова был определён его ранг.





Рис. 3: закон Ципфа

| rank | word | freq |
|------|------|---------|
| 1 | the | 2502562 |
| 2 | and | 1020405 |
| 3 | of | 932727 |
| 4 | to | 830274 |
| 5 | in | 713531 |
| 6 | game | 595295 |
| 7 | wa | 345416 |
| 8 | for | 336695 |
| 9 | as | 330005 |

Анализ графика показывает, что распределение слов по частотам близко к линейному в логарифмических координатах, что соответствует закону Ципфа. Отклонения наблюдаются для наиболее частотных слов и в хвосте распределения, что характерно для реальных текстовых корпусов.

4 Примеры существующих поисковых систем

Для анализа особенностей и ограничений современных поисковых систем были рассмотрены примеры поиска информации с использованием встроенного поиска Википедии и поисковой системы Google. В качестве запросов использовались термины, связанные с тематикой видеоигр.



The screenshot shows a Wikipedia search results page for the query "Video game". The search bar at the top contains the text "Video game". Below the search bar, there is a "Search" button. The main content area displays a list of search results, each with a thumbnail image, the title, and a brief description.

| Search Result | Description |
|-------------------------------|---|
| Video game | Electronic game with user interface and visual feedback |
| Video game industry | Economic sector of video games |
| Video game developer | Software developer specializing in the creation of video... |
| Video game console | Computer system for running video games |
| Video game modding | Fan-made modification of video games |
| Video game music | Music accompanying video games |
| Video game development | Process of developing a video game |
| Video game addiction | Addiction to playing video games |
| Video games in China | China's video game industry |
| Video game genre | Classification assigned to video games based on their ... |

At the bottom of the search results, there is a link to "Search for pages containing Video game".

Рис. 4: поиск википедия




Рис. 5: поиск гугл

Анализ полученных результатов показывает, что существующие поисковые системы ориентированы на массового пользователя и популярные источники. При этом поиск по узкоспециализированным запросам часто требует дополнительного уточнения, а структура выдачи может содержать нерелевантные результаты или служебную информацию.

5 Индексация и поиск

Для обеспечения быстрого поиска по корпусу документов был реализован булев инвертированный индекс. Инвертированный индекс сопоставляет каждому терму список идентификаторов документов, в которых данный терм встречается. Такая структура позволяет эффективно выполнять операции логического поиска без полного перебора всех документов.

В процессе индексирования каждый документ обрабатывается независимо. Для каждого документа формируется набор уникальных термов, которые затем добавляются в соответствующие постинг-листы. Результаты индексирования сохраняются на диске в виде словаря терминов и бинарно-

го файла постинг-листов, что позволяет повторно использовать индекс без необходимости пересчёта.

```
> head index/dict.tsv
term      df      offset  len
0-0       8        0       32
0-0-7     1        32      4
0-00-713655-2 1        36      4
0-00-717558-2 1        40      4
0-00-720907-x 3        44      12
0-007-24622-6 2        56      8
0-02-935671-7 1        64      4
0-049-28039-2 1        68      4
0-06-083305-x 1        72      4

> wc -l index/dict.tsv
274105 index/dict.tsv

> ls -lh index/dict.tsv index/postings.bin index/maxdoc.txt
-rwxrwxrwx 1 user user 5.9M Dec 26 12:25 index/dict.tsv
-rwxrwxrwx 1 user user    6 Dec 26 12:25 index/maxdoc.txt
-rwxrwxrwx 1 user user  46M Dec 26 12:25 index/postings.bin

> cat index/maxdoc.txt
30000
```

6 Пример работы поисковой системы

Для демонстрации работы реализованной поисковой системы были выполнены несколько булевых запросов с использованием логических операторов AND, OR и NOT. В результате выполнения запросов система возвращает список идентификаторов документов, удовлетворяющих условиям запроса.

```
Loaded terms: 274104
Universe docs: 1..30000
Enter queries. Ctrl+D to exit.

nintendo
RESULTS 8905
1
...
30000
END

10-year AND NOT 10-year-old
RESULTS 46
```

```
3
...
29891
END

10-year-old OR 10-year
RESULTS 81
3
...
28337
29891
END

(10-minute OR 10-yard) AND 10-year
RESULTS 0
END
```

7 Статистика работы системы

Для оценки эффективности реализованной системы была измерена производительность основных этапов обработки данных. В частности, были зафиксированы время построения индекса и среднее время обработки одного поискового запроса.

```
> /usr/bin/time -p ./build_index --stems stems --out index

Processed docs: 500, pairs: 337955
Processed docs: 1000, pairs: 565153
...
Processed docs: 30000, pairs: 11974986
Index built.
Docs processed: 30000
maxDoc: 30000
Output: index/dict.tsv, postings.bin, maxdoc.txt
real 39.78
user 8.13
sys 3.67
```

8 Заключение

В ходе выполнения данной работы были изучены основные принципы построения поисковых систем, включая сбор и подготовку корпуса документов, анализ статистических свойств текста, индексирование и реализацию булевого поиска. Реализованная система демонстрирует корректную рабо-

ту логических операций поиска и может быть расширена для поддержки более сложных методов ранжирования и анализа текстов.